



Institut National des Sciences Appliquées et de Technologie

4^{ème} Année • Génie Logiciel • Année Universitaire 2025/2026

TRAITEMENT D'IMAGES

Compte Rendu No.1

Reconnaissance Automatique des Émotions Faciales

Membres du Groupe

- Rayen Chemlali
- Mohamed Dhia Medini
- Khalil Ghimaji
- Mohamed Achref Hemissi

Informations

Filière	Génie Logiciel
Matière	Traitement d'Images
Sujet	Sujet 2 : Émotions faciales
Dataset	FER2013

Table des matières

1	Problématique	3
1.1	Contexte général	3
1.2	Applications visées	3
1.3	Problématique centrale	3
1.4	Sous-questions de recherche	3
1.5	Défis techniques identifiés	4
2	Objectifs du Projet	4
2.1	Objectif principal	4
2.2	Critères de réussite	4
2.3	Approche envisagée	4
2.4	Outils et technologies	5
3	Description des Données	5
3.1	Présentation du dataset FER2013	5
3.1.1	Caractéristiques techniques	6
3.1.2	Distribution des classes (chiffres vérifiés)	6
3.2	Analyse de la qualité des données	7
3.2.1	Points forts	7
3.2.2	Limites et défis identifiés	7
3.3	Stratégie de gestion des données	8
3.3.1	Prétraitement prévu (Semaine 2)	8
3.3.2	Augmentation de données prévue	8
	Conclusion	8

1 Problématique

1.1. Contexte général

Les émotions constituent un canal essentiel de la communication humaine. Leur détection automatique ouvre des perspectives majeures dans des secteurs variés : interaction homme-machine, assistance médicale, éducation adaptative et sécurité. Avec l'essor des réseaux de neurones convolutifs (CNN) et des architectures légères (MobileNet, EfficientNet), il est aujourd'hui possible d'exécuter ces modèles en temps réel sur du matériel grand public.

Cependant, la reconnaissance automatique des expressions faciales reste un défi technique en raison de la variabilité des expressions selon les individus, les cultures et les conditions d'acquisition (luminosité, pose, occultation).

1.2. Applications visées

Domaines d'application concrets

- **Éducation** : Détection de l'engagement des étudiants en cours présentiel ou e-learning adaptatif
- **Santé** : Assistance aux personnes atteintes de troubles du spectre autistique (TSA) pour la compréhension des émotions
- **Commerce** : Évaluation automatique de la satisfaction client
- **Sécurité routière** : Détection de la fatigue et de l'inattention du conducteur en temps réel
- **Bien-être mental** : Suivi émotionnel dans des applications thérapeutiques

1.3. Problématique centrale

Comment concevoir un système d'apprentissage profond capable de reconnaître automatiquement les sept émotions de base à partir d'images faciales avec une précision satisfaisante, en gérant le déséquilibre de classes, la faible résolution et les ambiguïtés inter-classes, tout en restant déployable en temps réel sur matériel standard ?

1.4. Sous-questions de recherche

1. Quelle architecture CNN offre le meilleur compromis précision / coût computationnel pour la classification sur FER2013 ?
2. Comment gérer le fort déséquilibre de classes (classe *Dégoût* : seulement 436 images en entraînement) ?
3. Quelles techniques d'augmentation améliorent la généralisation sans surapprentissage ?
4. Comment adapter le modèle à une inférence webcam en temps réel ?

1.5. Défis techniques identifiés

Déséquilibre de classes : la classe *Dégoût* (436 images en entraînement) représente environ 1,5 % du dataset, contre 25,1 % pour *Joie* (7 215 images). Ce biais devra être traité explicitement en Semaine 2.

- **Faible résolution :** 48×48 px limite la discrimination des micro-expressions
- **Ambiguïté inter-classes :** confusions fréquentes *Tristesse/Neutre* et *Peur/Surprise*
- **Bruit dans les annotations :** étiquettes issues de Google Image Search avec qualité variable

2 Objectifs du Projet

2.1. Objectif principal

Concevoir, entraîner et évaluer un **pipeline complet** de reconnaissance des émotions faciales capable de classifier les 7 émotions de FER2013 avec une **précision** $\geq 65\%$ sur l'ensemble de test.

2.2. Critères de réussite

- Accuracy $\geq 65\%$ sur le test set FER2013
- Matrice de confusion complète avec analyse des erreurs inter-classes
- Code source propre, commenté et versionné sur GitHub
- Démonstration fonctionnelle via interface Streamlit ou Gradio

2.3. Approche envisagée

1. **Phase 1 -> Baseline CNN :** architecture CNN simple (inspirée de VGG) entraînée *from scratch* pour établir une référence de performance
2. **Phase 2 -> Transfer Learning :** fine-tuning de **ResNet-50** ou **EfficientNet-B0** pré-entraîné sur ImageNet

2.4. Outils et technologies

Catégorie	Outils / Bibliothèques
Langage	Python 3.10+
Deep Learning	PyTorch ou TensorFlow / Keras
Vision	OpenCV, Pillow
Analyse	NumPy, Pandas, Matplotlib, Seaborn, Scikit-learn
Dét. visage	Haar Cascade (OpenCV), MTCNN
Interface	Streamlit ou Gradio
Versioning	Git / GitHub
Environnement	Google Colab (GPU) / Kaggle Notebooks

3 Description des Données

3.1. Présentation du dataset FER2013

Le jeu de données est le **FER2013** (*Facial Expression Recognition 2013*), introduit lors de la compétition ICML 2013 par Pierre Luc Carrier et Aaron Courville (Université de Montréal). Il a été constitué via l'API Google Image Search et constitue l'un des benchmarks les plus référencés en reconnaissance d'expressions faciales.

3.1.1. Caractéristiques techniques

Caractéristique	Valeur
Nombre total d'images	35 887 images
Format	Niveaux de gris (<i>grayscale</i>)
Résolution	48 × 48 pixels
Split entraînement	28 709 images
Split validation	3 589 images
Split test	3 589 images
Nombre de classes	7 émotions
Source	Kaggle / TensorFlow Datasets
Origine	API Google Image Search - ICML 2013

3.1.2. Distribution des classes (chiffres vérifiés)

La distribution est **fortement déséquilibrée** : la classe *Dégoût* est environ **16 fois moins représentée** que la classe *Joie*.

Label	Émotion	Total	Entraînement	% Total
0	Colère (<i>Angry</i>)	4 953	3 995	13.8 %
1	Dégoût (<i>Disgust</i>) *	547	436	1.5 %
2	Peur (<i>Fear</i>)	5 121	4 097	14.3 %
3	Joie (<i>Happy</i>)	8 989	7 215	25.1 %
4	Tristesse (<i>Sad</i>)	6 077	4 830	16.9 %
5	Surprise	4 002	3 171	11.2 %
6	Neutre (<i>Neutral</i>)	6 198	4 965	17.3 %
TOTAL		35 887	28 709	100 %

* **Déséquilibre critique** : *Dégoût* = 1.5 % du total (436 images en entraînement) contre 25.1 % pour *Joie* (7 215 images). Ce déséquilibre sera traité en Semaine 2 via class weights et/ou sur-échantillonnage augmenté.

3.2. Analyse de la qualité des données

3.2.1. Points forts

- Dataset public et bien établi, benchmark de référence depuis 2013
- Images déjà alignées et recadrées sur les visages
- Disponibilité directe sur Kaggle et via TensorFlow Datasets
- Diversité des sujets (âges, ethnies, conditions d'acquisition)
- Partitions train / val / test prédéfinies pour la reproductibilité

3.2.2. Limites et défis identifiés

- **Déséquilibre de classes** : *Dégoût* (547) vs *Joie* (8 989 images)
- **Très faible résolution (48×48 px)** : micro-expressions difficiles à percevoir

- **Qualité variable des annotations** : images collectées via Google Image Search, bruit non négligeable
- **Ambiguïté inter-classes** : confusions fréquentes *Tristesse/Neutre* et *Peur/Surprise*
- **Conditions d'acquisition variées** : éclairage, pose et occultations non standardisés

3.3. Stratégie de gestion des données

3.3.1. Prétraitement prévu (Semaine 2)

- Normalisation des pixels dans $[0, 1]$
- Conservation de la résolution 48×48 px
- Conversion en tenseurs PyTorch / TensorFlow
- Vérification et nettoyage des étiquettes aberrantes

3.3.2. Augmentation de données prévue

- Retournement horizontal aléatoire (*horizontal flip*)
- Rotation légère ($\pm 10^\circ$)
- Zoom aléatoire ($\pm 10\%$)
- Ajustement de la luminosité et du contraste
- Sur-échantillonnage ciblé de la classe *Dégoût*
- *Class weights* dans la fonction de perte

Conclusion

Ce premier compte rendu répond aux trois exigences du Livrable CR1 :

- **Problématique** : question centrale formulée, défis techniques et applicatifs identifiés
- **Objectifs** : critères de réussite mesurables ($\text{accuracy} \geq 65\%$, inférence temps réel) et feuille de route sur 6 semaines
- **Description des données** : analyse détaillée de FER2013 (35 887 images, distribution vérifiée, limites et stratégie)

Références Bibliographiques

Références

- [1] I. J. Goodfellow, D. Erhan, P. L. Carrier, A. Courville *et al.*, “Challenges in Representation Learning : A Report on Three Machine Learning Contests,” *Neural Networks*, vol. 64, pp. 59–63, 2015. Données disponibles sur Kaggle : <https://www.kaggle.com/datasets/msambare/fer2013>
- [2] K. Simonyan et A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” *Proceedings of ICLR*, 2015. <https://arxiv.org/abs/1409.1556>
- [3] K. He, X. Zhang, S. Ren et J. Sun, “Deep Residual Learning for Image Recognition,” *Proceedings of CVPR*, pp. 770–778, 2016. <https://arxiv.org/abs/1512.03385>
- [4] M. Tan et Q. V. Le, “EfficientNet : Rethinking Model Scaling for Convolutional Neural Networks,” *Proceedings of ICML*, vol. 97, pp. 6105–6114, 2019. <https://arxiv.org/abs/1905.11946>
- [5] A. G. Howard, M. Zhu, B. Chen *et al.*, “MobileNets : Efficient Convolutional Neural Networks for Mobile Vision Applications,” *arXiv preprint*, arXiv :1704.04861, 2017. <https://arxiv.org/abs/1704.04861>
- [6] B. Ko, “A Brief Review of Facial Emotion Recognition Based on Visual Information,” *Sensors*, vol. 18, no. 2, p. 401, 2018. <https://doi.org/10.3390/s18020401>
- [7] N. V. Chawla, K. W. Bowyer, L. O. Hall et W. P. Kegelmeyer, “SMOTE : Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.