



Institut National des Sciences Appliquées et de Technologie

4^{ème} Année • Génie Logiciel • Année Universitaire 2025/2026

TRAITEMENT D'IMAGES

Compte Rendu No.5

Évaluation du Système FER — Reconnaissance des Émotions Faciales

Membres du Groupe

- Mohamed Ahref Hemissi
- Mohamed Dhia Medini
- Khalil Ghimaji
- Rayen Chemlali

Informations

Filière	Génie Logiciel
Matière	Traitement d'Images
Semaine	Semaine 5 : Évaluation
Dataset	FER2013

Table des matières

1	Introduction et Protocole d'Évaluation	3
1.1	Contexte	3
1.2	Modèles évalués	3
1.3	Protocole d'évaluation	3
2	Métriques Globales	4
2.1	Rappel des Définitions	4
3	Matrices de Confusion	4
3.1	Présentation	4
3.2	Analyse par Classe	5
4	Métriques par Classe	6
4.1	Observations	6
5	Tests sur Nouvelles Données	6
5.1	Tests depuis le Dataset FER2013	6
5.2	Tests sur Images Externes (hors FER2013)	7
5.3	Interprétation des Tests Externes	9
6	Analyse des Erreurs	9
6.1	Paires de Confusion les Plus Fréquentes	9
6.2	Explication des Confusions	10
7	Récapitulatif et Dynamique d'Apprentissage	11
8	Analyse Critique	11
8.1	Points Forts	11
8.2	Points Faibles	12
8.3	Comparaison avec l'État de l'Art	13
8.4	Pistes d'Amélioration	13
9	Conclusion	14

1 Introduction et Protocole d'Évaluation

1.1. Contexte

Cette cinquième semaine conclut le cycle de développement du système de reconnaissance des émotions faciales. Après avoir conçu le pipeline de prétraitement (S2), défini les architectures (S3) et conduit l'entraînement (S4), l'objectif de cette semaine est l'**évaluation objective** des trois modèles entraînés sur un ensemble de test indépendant.

1.2. Modèles évalués

Modèle	Paramètres	Profondeur	Val. Acc. (S4)	Epochs	Surapp.
Baseline CNN	~390 K	4 blocs conv	62,47 %	32/46	-3,6 %
Deep CNN	~1,5 M	4 blocs doubles+SE	68,32 %	98/100	+4,8 %
EfficientNet-B0	~4 M	Backbone pré-entraîné	66,94 %	97/100	+30,6 %

Note : La colonne *Val. Acc. (S4)* correspond à l'accuracy de **validation** mesurée durant l'entraînement (Semaine 4). Les résultats sur l'ensemble de **test** indépendant (Section 2) sont systématiquement inférieurs.

1.3. Protocole d'évaluation

- **Ensemble de test :** 7178 images issues du dossier `test/` de FER2013, jamais vues durant l'entraînement.
- **Prétraitement :** identique à la validation — débruitage gaussien → CLAHE → normalisation ($\mu = 0,563$, $\sigma = 0,2627$).
- **Métriques calculées :** Accuracy, Précision, Rappel et F1-Score (macro et pondéré) pour chaque modèle et chaque classe.
- **Tests externes :** images téléchargées depuis Internet, totalement inconnues du modèle, placées dans `data/new_images/`.

2 Métriques Globales

Le tableau ci-dessous présente les métriques de performance de chaque modèle sur l’ensemble de test complet (7 178 images, 7 classes).

Modèle	Accuracy	Précision (macro)	Rappel (macro)	F1 (macro)	F1 (pondéré)
Baseline CNN	56,09 %	53,8 %	57,1 %	51,9 %	56,8 %
Deep CNN	65,19 %	61,2 %	64,6 %	62,4 %	65,1 %
EfficientNet-B0	61,67 %	61,2 %	60,1 %	60,4 %	61,5 %

Interprétation

Le **Deep CNN** obtient les meilleures performances sur toutes les métriques. L’écart entre le F1 macro (~62 %) et le F1 pondéré (~65 %) révèle l’impact du déséquilibre de classes : les classes rares (Disgust, Fear) tirent la moyenne macro vers le bas.

2.1. Rappel des Définitions

Soient VP (vrais positifs), FP (faux positifs), FN (faux négatifs) :

$$\text{Accuracy} = \frac{\sum_c VP_c}{N_{\text{total}}} \tag{1}$$

$$\text{Précision}_c = \frac{VP_c}{VP_c + FP_c} \tag{2}$$

$$\text{Rappel}_c = \frac{VP_c}{VP_c + FN_c} \tag{3}$$

$$F1_c = 2 \times \frac{\text{Précision}_c \times \text{Rappel}_c}{\text{Précision}_c + \text{Rappel}_c} \tag{4}$$

3 Matrices de Confusion

3.1. Présentation

La matrice de confusion normalisée par ligne permet de visualiser, pour chaque vraie classe i , la distribution des prédictions sur les 7 émotions. La diagonale principale correspond au **rappel** par classe.




FIGURE 1 – Matrices de confusion normalisées (par ligne) sur l'ensemble de test. Chaque cellule (i, j) indique la proportion d'images de la classe i classées comme classe j .

3.2. Analyse par Classe

Classe	Bien reconnue ?	Confusion principale	Rappel
Happy	Oui — très distinctif	Surprise parfois	~86 %
Surprise	Oui	Happy, Fear	~78 %
Neutral	Moyen	Sad, Angry	~59 %
Angry	Moyen	Disgust, Neutral	~58 %
Sad	Moyen	Neutral, Fear	~56 %
Fear	Difficile	Sad, Angry, Surprise	~43 %
Disgust	Rappel élevé, précision faible	Angry (faux positifs)	~72 %

La confusion **Fear** → **Sad** et **Sad** → **Neutral** est cohérente : ces émotions partagent des caractéristiques faciales proches (sourcils baissés, bouche légèrement ouverte ou fermée).

4 Métriques par Classe




FIGURE 2 – Précision, Rappel et F1-Score par classe pour les trois modèles.

4.1. Observations

- **Happy et Surprise** : les deux classes les mieux reconnues par tous les modèles. Leurs expressions faciales sont visuellement distinctes (sourire prononcé, bouche ouverte).
- **Disgust** : comportement asymétrique — rappel élevé ($\sim 72\%$) mais précision faible ($\sim 44\%$, $F1 \sim 54\%$). Le `WeightedRandomSampler` pousse le modèle à sur-prédire Disgust, générant de nombreux faux positifs depuis la classe Angry.
- **Fear vs Sad** : ces deux émotions sont régulièrement confondues. Le modèle Deep CNN les distingue légèrement mieux grâce aux blocs d'attention Squeeze-and-Excitation (SE).
- L'**EfficientNet-B0** présente des performances inférieures au Deep CNN malgré ses 4M de paramètres — preuve que la capacité du modèle ne suffit pas sans adaptation au domaine (images 48×48 en niveaux de gris vs ImageNet 224×224 RGB).

5 Tests sur Nouvelles Données

5.1. Tests depuis le Dataset FER2013

Des images aléatoires de l'ensemble de test sont soumises au Deep CNN avec affichage de la vraie étiquette et de la prédiction.




FIGURE 3 – Prédictions du Deep CNN sur des exemples aléatoires du test set FER2013. Vert = prédiction correcte, Rouge = erreur.

5.2. Tests sur Images Externes (hors FER2013)

Des images de visages téléchargées depuis Internet sont soumises au modèle. Ces images sont **totalelement inconnues** du modèle. Elles ne font partie d'aucun split d'entraînement ni de test du dataset FER2013.




FIGURE 4 – Prédictions du Deep CNN sur images externes (hors FER2013). Le label vrai est déduit du nom du fichier.




FIGURE 5 – Distribution de probabilité (softmax) pour chaque image externe. La barre verte indique la vraie classe, rouge la classe prédite (si différente).

5.3. Interprétation des Tests Externes

Les images réelles issues d'Internet présentent des conditions différentes de FER2013 :

- **Résolution** : les images originales peuvent être très haute résolution, redimensionnées à 48×48 — perte de détail potentielle.
- **Fond et pose** : FER2013 contient des visages centrés, souvent de face. Des images avec visage de profil ou fond complexe peuvent dégrader la performance.
- **Ethnicité et âge** : FER2013 présente un biais démographique ; le modèle peut être moins robuste sur des visages sous-représentés.

Note : Ces observations illustrent le problème de **domain shift** entre les données d'entraînement et les données réelles.

6 Analyse des Erreurs

6.1. Paires de Confusion les Plus Fréquentes




FIGURE 6 – Top des confusions du Deep CNN sur l'ensemble de test. Chaque barre représente le nombre d'images de la vraie classe prédites à tort dans la classe indiquée.



FIGURE 7 – Exemples d'images mal classées par le Deep CNN pour les 4 paires de confusion les plus fréquentes.

6.2. Explication des Confusions

Les principales confusions observées ont une explication physiologique :

- **Fear** → **Sad** : sourcils levés + bouche ouverte (Fear) peuvent ressembler à sourcils baissés + bouche tombante (Sad) sur des images 48×48 à faible résolution.
- **Sad** → **Neutral** : expressions de tristesse légère proches d'un visage neutre — manque de mouvement facial prononcé.
- **Angry** → **Disgust** : les deux émotions impliquent un front plissé et un regard intense ; la différence principale (narine dilatée, lèvre supérieure relevée) est difficile à capturer sur 48×48 pixels.
- **Disgust** → **Angry** : confusion symétrique pour les mêmes raisons anatomiques.

7 Récapitulatif et Dynamique d'Apprentissage




FIGURE 8 – Courbes de validation des trois modèles sur 100 epochs. Les points marquent le meilleur epoch de chaque modèle.




FIGURE 9 – Comparaison finale des trois modèles : Accuracy, F1 macro et F1 pondéré sur l'ensemble de test. La ligne pointillée indique l'objectif de 70 %.

8 Analyse Critique

8.1. Points Forts

Ce qui fonctionne bien

- 1. Deep CNN — meilleur rapport performance/complexité.** 65,2% d'accuracy avec seulement 1,5M de paramètres. Le surapprentissage est contrôlé (+4,8% train vs val en S4), signe d'une bonne régularisation (Dropout, BatchNorm, SE attention).
- 2. Pipeline de prétraitement efficace.** Le débruitage gaussien + CLAHE améliore le contraste des images et contribue à la robustesse. La normalisation calculée *après* CLAHE (et non sur les données brutes) évite une fuite de données (data leakage).
- 3. Gestion du déséquilibre de classes.** Le `WeightedRandomSampler` équilibre les

batches d'entraînement sans modifier la fonction de perte, ce qui permet au modèle de ne pas ignorer la classe Disgust (547 images seulement).

4. **Happy et Surprise bien reconnues.** Rappel $> 75\%$ sur ces deux classes, prouvant que le modèle apprend des représentations discriminantes pour les expressions faciales les plus distinctives.

8.2. Points Faibles

Limitations identifiées :

1. **Disgust : précision insuffisante malgré un bon rappel.** Le rappel atteint $\sim 72\%$ grâce au sampler, mais la précision chute à $\sim 44\%$ ($F1 \sim 54\%$) : le modèle sur-prédit Disgust et génère de nombreux faux positifs depuis Angry.
2. **EfficientNet-B0 inadapté au domaine.** Les poids ImageNet (entraînés sur 224×224 RGB) ne se transfèrent pas bien aux images 48×48 niveaux de gris. Le surapprentissage massif ($+30,6\%$) le confirme : le backbone mémorise plutôt qu'il ne généralise.
3. **Plafond de FER2013 à $\sim 70\%$.** L'accord inter-annotateurs humains sur FER2013 est estimé à $65-70\%$. Notre Deep CNN ($65,2\%$) approche ce plafond, ce qui signifie que les marges de progression sur ce dataset sont limitées sans changement de dataset ou d'architecture majeur.
4. **Sensibilité au domaine (domain shift).** Les tests sur images externes montrent que le modèle est plus fragile hors du contexte FER2013 : fond neutre, visage centré, faible résolution.
5. **Ambiguïté des émotions.** Fear, Sad et Neutral sont intrinsèquement ambigus même pour un observateur humain. Cette ambiguïté se reflète dans les confusions du modèle et est irréductible sans annotation plus fine.

8.3. Comparaison avec l'État de l'Art

Approche	Accuracy (Test)	Référence
Accord inter-humains (limite)	~65–70 %	FER2013 paper
CNN [26]	62,44 %	Littérature
GoogLeNet [30]	65,20 %	Littérature
Notre Deep CNN	65,19 %	Ce travail
VGG+SVM [29]	66,31 %	Littérature
Attentional ConvNet [27]	70,02 %	Littérature
ResNet [34]	72,40 %	Littérature
Vision Transformer (ViT-B/16)	75,6 %	Littérature

Notre Deep CNN (65,19 %) se positionne **au-dessus du CNN de base** (+2,75 %) et atteint un niveau équivalent à GoogLeNet (65,20 %), avec $7\times$ moins de paramètres. Il reste à 5 % des méthodes avec attention et à 7 % des architectures de transfert learning profondes.

8.4. Pistes d'Amélioration

- Label Smoothing** ($\varepsilon = 0,1$) : réduit l'overconfidence du modèle et améliore la calibration des probabilités. Déjà prévu dans `config.yaml` mais non activé.
- Augmentations avancées** : Mixup, CutMix ou RandAugment pour mieux régulariser le Deep CNN et réduire le surapprentissage.
- Ensemble des modèles** : la moyenne des softmax des 3 modèles peut gagner 1–2 % d'accuracy sans entraînement supplémentaire.
- Changer de dataset** : AffectNet (450K images) ou RAF-DB (30K images en conditions réelles) permettraient un meilleur transfert sur des données réelles.
- Architecture moderne** : un ConvNeXt-Tiny ou un ViT léger entraîné from scratch sur 48×48 grayscale pourrait dépasser 70 %.

9 Conclusion

Bilan de la Semaine 5

Cette semaine d'évaluation conclut le cycle de développement du système FER.

Résultats principaux :

- Le **Deep CNN** est le meilleur modèle : 65,2 % d'accuracy, F1 macro ~62 %, généralisation saine (+4,8 % train/val en S4).
- **Happy** et **Surprise** sont bien reconnues ; **Fear** reste problématique (~43 % rappel) ; **Disgust** affiche un bon rappel mais une précision faible (~44 %).
- Les tests sur images externes confirment le phénomène de **domain shift** inhérent à FER2013.
- Le plafond du dataset (~70 %) est presque atteint. Des futures améliorations nécessiteraient un changement de dataset ou d'architecture.

Bilan des 5 semaines : le projet a couvert l'intégralité du pipeline d'apprentissage automatique, de l'analyse du dataset et du prétraitement (S2) à la conception des architectures (S3), l'entraînement (S4) et l'évaluation rigoureuse (S5).