



Institut National des Sciences Appliquées et de Technologie

4^{ème} Année • Génie Logiciel • Année Universitaire 2025/2026

TRAITEMENT D'IMAGES : RAPPORT FINAL

Reconnaissance des Émotions Faciales

FER2013 : Pipeline complet

Dataset • Prétraitement • Architectures • Entraînement • Évaluation • Démo

Membres du Groupe

- Mohamed Achref Hemissi
- Mohamed Dhia Medini
- Khalil Ghimaji
- Rayen Chemlali

Informations

Filière	Génie Logiciel
Matière	Traitement d'Images
Période	S1–S5 (Mars – Avril 2026)
Dataset	FER2013 (Kaggle)
Modèle	Deep CNN (1,33M param.)
Accuracy	65,2 % (test set)

Table des matières

1	Introduction et Contexte du Projet	4
1.1	Objectif	4
1.2	Feuille de Route	4
2	Analyse du Dataset FER2013	4
2.1	Caractéristiques	5
2.2	Déséquilibre de Classes	5
2.3	Vérification d'Intégrité	6
2.4	Origine et Qualité des Images	6
3	Pipeline de Prétraitement (Semaine 2 – corrigé en S3)	6
3.1	Vue d'Ensemble	7
3.2	Débruitage Gaussien	8
3.2.1	Pourquoi un filtre gaussien ?	8
3.3	CLAHE : Normalisation Locale du Contraste	9
3.3.1	Pourquoi la CLAHE plutôt qu'une égalisation globale ?	9
3.4	Normalisation Statistique	10
3.4.1	Lecture de l'image normalisée (colormap RdBu)	10
3.5	Exemples Concrets du Pipeline (application Streamlit)	11
4	Conception des Architectures (Semaine 3)	11
4.1	Trois architectures comparées	11
4.2	Bloc d'Attention Squeeze-and-Excitation (SE)	12
4.3	Adaptation d'EfficientNet-B0 au Domaine	12
4.4	Augmentation de Données	13
5	Stratégie d'Entraînement (Semaine 4)	14
5.1	Configuration	14
5.2	Gestion du Déséquilibre de Classes	15
5.3	Résultats d'Entraînement	16
6	Évaluation Complète (Semaine 5)	17
6.1	Métriques Globales	17
6.2	Matrices de Confusion	17
6.3	Métriques par Classe (Deep CNN)	18
6.4	Analyse des Erreurs	19
6.5	Sur le Modèle d'Ensemble	20
7	Application Interactive Streamlit	20
7.1	Présentation	20
7.2	Fonctionnalités	21
7.3	Observation Critique : Comportement en Conditions Réelles	21
7.4	Résultats des Tests Externes	21

8	Comparaison avec l'État de l'Art	23
9	Analyse Critique Globale	24
9.1	Ce qui Fonctionne	24
9.2	Limitations Identifiées	24
9.3	Pistes d'Amélioration	24
10	Conclusion	25

1 Introduction et Contexte du Projet

1.1. Objectif

L'objectif de ce projet est de concevoir et évaluer un système de **reconnaissance automatique des émotions faciales** à partir d'images en niveaux de gris. Le système doit classifier chaque image dans l'une des 7 émotions suivantes :

Angry Disgust Fear Happy Sad Surprise Neutral

Ce problème est représentatif des défis réels du traitement d'images : déséquilibre de classes, bruit, faible résolution, et ambiguïté intrinsèque des données.

1.2. Feuille de Route

S	Date	Thème	Livrable
S1	30/03/2026	Cadrage du projet, choix du dataset	CR1 (PDF)
S2	06/04/2026	Pipeline de prétraitement des images	CR2 (notebook + PDF)
S3	13/04/2026	Conception des architectures	CR3 (notebook + PDF)
S4	20/04/2026	Entraînement : benchmark 3 modèles	CR4 (notebook + PDF)
S5	27/04/2026	Évaluation complète + tests réels	CR5 (notebook + PDF)

2 Analyse du Dataset FER2013

2.1. Caractéristiques

Propriété	Valeur
Nombre total	35 887 images
Format	Niveaux de gris, 48×48 pixels
Classes	7 émotions (Angry, Disgust, Fear, Happy, Sad, Surprise, Neutral)
Source	Kaggle : msambare/fer2013
Structure	Dossiers <code>train/</code> et <code>test/</code> , un sous-dossier par classe
Origine	Images scrapées depuis Internet (moteurs de recherche)

2.2. Déséquilibre de Classes




FIGURE 1 – Distribution des classes dans le dataset FER2013. Le déséquilibre est sévère : Disgust (547 images) vs Happy (8 989 images), ratio 1 :16.

Problème créant un biais majeur : Sans correction, un modèle naïf qui prédit toujours “Happy” obtiendrait ~25 % d’accuracy sur le train set sans rien apprendre. Ce déséquilibre est compensé par un `WeightedRandomSampler` lors de l’entraînement (Section 5).

2.3. Vérification d'Intégrité

Métrique	Résultat	Remarque
Total	35 887	Échantillon complet
Valides	35 887 (100 %)	Aucun fichier corrompu
Corrompus	0	Aucun
Doublons MD5	1 853	Conservés (distribution originale)

2.4. Origine et Qualité des Images

Les images FER2013 ont été **scrapées depuis Internet**, elles ont subi plusieurs cycles de compression JPEG (publication, téléchargement, re-publication) avant d'être intégrées au dataset. Cela explique deux phénomènes importants :

- **Bruit JPEG** : artefacts de bloc autour des bords, pixels aberrants non représentatifs de l'émotion.
- **Variété d'éclairage** : les images proviennent de contextes très différents (studio, extérieur, vidéo comprimée). La CLAHE est nécessaire pour homogénéiser.

Impact de la résolution : À 48×48 pixels, un seul pixel aberrant représente $1/2304$ de l'image, soit $\sim 2,2\%$, ce qui est significatif pour le réseau. Sur une image normale (12 M pixels), ce même pixel ne représente que $0,00001\%$. C'est pourquoi même un débruitage léger a un impact mesurable ici.

3 Pipeline de Prétraitement (Semaine 2 – corrigé en S3)

3.1. Vue d'Ensemble




FIGURE 2 – Visualisation du pipeline de prétraitement complet sur des exemples représentatifs du dataset.

Le pipeline comporte 4 étapes appliquées dans cet ordre :

- Étape 1** Vérification d'intégrité (MD5, fichiers corrompus, labels)
- Étape 2** Débruitage gaussien
- Étape 3** Normalisation du contraste (CLAHE)
- Étape 4** Normalisation statistique

3.2. Débruitage Gaussien




FIGURE 3 – Effet du débruitage gaussien sur des images du dataset. Les artefacts JPEG sont atténués sans perdre les contours faciaux.

3.2.1. Pourquoi un filtre gaussien ?

Plusieurs options existent pour le débruitage :

Filtre	Avantage	Inconvénient
Gaussien	Le plus léger, matché au bruit JPEG	Légère perte de contours
Médian	Excellent pour le bruit poivre/sel	Trop agressif sur 48×48
Bilatéral	Préserve les bords nets	Lent, surpuissant pour ce format
Moyenneur (box)	Simple	Artefacts de bloc aux bords

La raison spécifique à FER2013 n'est pas générique : le bruit provient principalement des **artefacts de compression JPEG répétée** (images scrapées depuis Internet). Ce type de bruit est mathématiquement gaussien (distribution aléatoire en cloche). Le filtre gaussien est donc le **filtre optimal** pour ce type de bruit. De plus, un $\sigma = 0,8$ avec noyau 3×3 est le traitement le plus léger possible, indispensable à 48×48 où chaque pixel porte de l'information sur l'émotion.

Paramètres choisis

Noyau : 3×3 $\sigma : 0,8$

Un σ plus grand lissait les sourcils, la bouche et les plissements, des features discriminantes pour classifier les émotions. Un $\sigma = 0,8$ atténue les speckles sans toucher les structures.

3.3. CLAHE : Normalisation Locale du Contraste



FIGURE 4 – Effet de la CLAHE sur plusieurs images. Les zones sombres (yeux, rides) sont révélées sans sur-exposer les zones déjà claires.

3.3.1. Pourquoi la CLAHE plutôt qu'une égalisation globale ?

L'égalisation d'histogramme classique (HE) traite l'image entière comme une seule unité. Si l'arrière-plan est très clair, les valeurs de pixel du visage sont écrasées. La CLAHE (Contrast Limited Adaptive Histogram Equalization) divise l'image en **tuiles locales** (ici $4 \times 4 = 16$ régions de 12×12 px sur une image 48×48) et égalise chaque tuile indépendamment.

Le paramètre `clipLimit=2,0` **plafonne** l'amplification locale : sans ce plafond, les tuiles quasi-uniformes verraient leur bruit amplifié drastiquement. Le clip redistribue l'excédent uniformément.

Résultat : chaque image, qu'elle soit surexposée ou sous-exposée, sort avec un contraste homogène. Le réseau voit des entrées cohérentes quelle que soit la condition d'éclairage originale.

3.4. Normalisation Statistique




FIGURE 5 – Visualisation de la normalisation. À gauche : image après CLAHE. À droite : image normalisée (colormap RdBu : rouge = zone sombre, bleu = zone claire, blanc = moyenne).

La formule appliquée est :

$$x_{\text{norm}} = \frac{x/255 - \mu}{\sigma}$$

avec $\mu = 0,563$ et $\sigma = 0,2627$ (calculés sur le train set après CLAHE).

Correction apportée en S3 (anti data leakage) : En S2, les statistiques avaient été calculées sur les pixels **bruts** avant CLAHE ($\mu = 0,507$, $\sigma = 0,255$). Ce choix était incorrect : les images subissent la CLAHE avant d'entrer dans le réseau, donc les statistiques doivent être calculées **après** CLAHE pour correspondre à ce que le modèle reçoit réellement. Les valeurs corrigées ($\mu = 0,563$, $\sigma = 0,2627$) ont été utilisées pour tout l'entraînement et l'évaluation.

Note : les statistiques sont calculées **uniquement sur le train set**. Les appliquer sur val/test serait une fuite de données (data leakage).


3.4.1. Lecture de l'image normalisée (colormap RdBu)

Dans la colormap RdBu utilisée pour visualiser les images normalisées :


- **Bleu** = valeurs positives = zones **claires** (pixel > moyenne)
- **Rouge** = valeurs négatives = zones **sombres** (pixel < moyenne)
- **Blanc** = zéro = pixel exactement à la moyenne

Ce n'est qu'une convention de visualisation ; le réseau reçoit un tenseur de flottants, pas une image colorée.

3.5. Exemples Concrets du Pipeline (application Streamlit)



(a) Émotion **Happy** : sourire bien visible, contraste homogène après CLAHE, zones claires (bleu) sur le front et les joues dans l'image normalisée.



(b) Émotion **Angry** : texture de barbe et contours du visage révélés par la CLAHE. Les zones sombres (rouge) dominent l'image normalisée, cohérent avec l'expression tendue.

FIGURE 6 – Pipeline de prétraitement complet appliqué à deux images réelles issues de l'application Streamlit. De gauche à droite : (1) Brut 48×48, (2) Débruitage gaussien ($\sigma = 0,8$), (3) CLAHE (clipLimit=2,0), (4) Normalisé ($\mu = 0,563$, $\sigma = 0,2627$).

4 Conception des Architectures (Semaine 3)

4.1. Trois architectures comparées




FIGURE 7 – Schémas des trois architectures implémentées.

Modèle	Paramètres	Description
Baseline CNN	~390 K	4× ConvBlock (Conv → BN → ReLU → Max-Pool), GAP, FC(7)
Deep CNN	~1,33 M	4× DoubleConvBlock + attention SE , GAP, FC(256 → 512 → 7)
EfficientNet-B0	~4 M	Backbone pré-entraîné ImageNet adapté : tige 1-canal, tête fine-tunée

4.2. Bloc d'Attention Squeeze-and-Excitation (SE)

Le Deep CNN intègre un bloc SE après chaque DoubleConvBlock. Ce mécanisme :

1. **Squeeze** : réduit la carte de features à un vecteur par canal (Global Average Pooling)
2. **Excitation** : apprend un poids par canal via deux couches FC et une sigmoïde
3. **Recalibration** : multiplie chaque canal par son poids appris

L'attention SE permet au réseau de se concentrer sur les canaux les plus discriminants pour chaque émotion, sans paraître surcoûteux (<1 % des paramètres totaux).

4.3. Adaptation d'EfficientNet-B0 au Domaine

EfficientNet-B0 est conçu pour des images **RGB 224×224** (ImageNet). Deux adaptations ont été appliquées :

- **Première couche conv** remplacée pour accepter 1 canal (niveaux de gris). Les poids pré-entraînés RGB sont **sommés** sur la dimension canal (conservation maximale de l'information ImageNet).
- **Tête de classification** remplacée par Dropout + FC(7).

Limitation anticipée : Les features ImageNet sont optimisées pour des objets naturels en couleur à haute résolution. Une image FER2013 (48×48, niveaux de gris) est fondamentalement différente du domaine d'entraînement : ce problème de **domain shift** est confirmé en S4 et S5.

4.4. Augmentation de Données



FIGURE 8 – Exemples d'augmentations appliquées durant l'entraînement.

Augmentation	Paramètre	Justification
Flip horizontal	$p = 0,5$	Une émotion est symétrique
Rotation	± 10	Variabilité de pose sans déformer
ColorJitter	brigh. 0.2, cont. 0.15	Simulation de conditions d’éclairage
RandomResizedCrop	scale [0,9, 1,1]	Légère variabilité spatiale

5 Stratégie d’Entraînement (Semaine 4)

5.1. Configuration

Paramètre	Valeur
Optimiseur	AdamW ($lr = 0,001$, $\lambda = 10^{-4}$)
Scheduler	CosineAnnealingLR ($T_{\max} = 100$, $\eta_{\min} = 10^{-6}$)
Fonction de perte	CrossEntropyLoss + poids de classe + label smoothing ($\varepsilon = 0,1$)
Batch size	128
Epochs max	100
Early stopping	patience = 15 epochs
Gestion du dés-équilibre	WeightedRandomSampler
Accélération	CUDA, AMP (mixed precision), <code>torch.cuda.amp</code>

5.2. Gestion du Déséquilibre de Classes

Deux mécanismes combinés :

1. **WeightedRandomSampler** : rééchantillonne les batches pour que chaque classe soit vue avec la même fréquence. Sans cela, Disgust (547 images) ne serait jamais suffisamment représenté.
2. **Poids de classe dans la perte** : les erreurs sur les classes rares sont pondérées plus fortement, forçant le gradient à y accorder plus d'attention.

Compromis accepté du WeightedRandomSampler

Le WeightedRandomSampler introduit de la **rédundance** : avec un ratio de déséquilibre de 1 :16 (Disgust vs Happy), chaque image Disgust est rééchantillonnée environ 16 fois plus souvent que chaque image Happy sur l'ensemble des epochs. Ce phénomène est **connu et anticipé**.

Nous avons choisi cette stratégie en connaissance de cause, car les alternatives présentent des inconvénients plus importants :

- **Sous-échantillonnage de Happy** : réduit artificiellement la taille du dataset, on perd des données réelles utiles au modèle.
- **Sur-échantillonnage synthétique (SMOTE)** : génère des images interpolées irréalistes pour des données visuelles, le réseau apprendrait sur des artefacts.
- **Pas de correction** : le modèle ignorerait Disgust et atteindrait $\sim 25\%$ d'accuracy en prédisant toujours "Happy".

Pour atténuer la rédundance, deux mesures complémentaires ont été appliquées : (1) **augmentation de données** aléatoire à chaque échantillonnage (flip, rotation, jitter), de sorte que le réseau ne voit jamais exactement les mêmes pixels ; (2) **label smoothing** ($\epsilon = 0,1$) qui empêche le modèle de devenir surconfiant sur les images répétées.

Il est important de noter que le WeightedRandomSampler **élimine** le biais de classe dans les batches : chaque batch contient autant d'images Disgust que Happy. Il n'introduit donc pas de biais de prédiction vers Disgust. Le problème est différent et plus subtil.

La rédundance (mêmes 547 images vues $16\times$ plus souvent) entraîne une **mémorisation** : le modèle apprend avec précision les patterns visuels de ces 547 visages spécifiques. Lorsqu'il rencontre un visage Angry qui partage des traits avec l'un de ces visages mémorisés (même tension faciale, même plissement), il le classe Disgust à tort. Cela explique :

- **Rappel élevé (72 %)** : les patterns Disgust sont bien mémorisés, le modèle les reconnaît facilement dans les vrais cas.
- **Précision faible (44 %)** : ces mêmes patterns mémorisés sont trop spécifiques, le

modèle les voit aussi dans des visages Angry proches des exemples d'entraînement, générant de faux positifs.

Ce compromis est jugé acceptable : il vaut mieux détecter Disgust avec trop de faux positifs que de le manquer complètement, étant donné sa rareté dans le dataset (547 images sur 35 887).

5.3. Résultats d'Entraînement




FIGURE 9 – Courbes de perte et d'accuracy sur les ensembles train et validation pour les 3 modèles.




FIGURE 10 – Évolution du learning rate (CosineAnnealingLR) sur 100 epochs.

Modèle	Val. Acc.	Epochs	Train Acc.	Écart train/val
Baseline CNN	62,47 %	32/46	58,86 %	−3,6 %
Deep CNN	68,32 %	98/100	73,15 %	+4,8 %
EfficientNet-B0	66,94 %	97/100	97,51 %	+30,6 %

EfficientNet-B0 : surapprentissage massif. 97,5 % sur le train vs 66,9 % en validation, écart de 30,6 points. Le backbone mémorise les exemples plutôt qu'il ne généralise. Les features ImageNet (RGB, 224×224) ne sont pas transférables vers des images 48×48 niveaux de gris sans fine-tuning approfondi ou gel du backbone. Ce comportement est confirmé par les résultats de test (S5) où EfficientNet chute à 61,7 %.

6 Évaluation Complète (Semaine 5)

Distinction validation / test : L'accuracy de validation (S4) est mesurée sur un sous-ensemble du dataset utilisé pour sélectionner les checkpoints. L'accuracy de test (S5) est mesurée **une seule fois**, sur un ensemble totalement indépendant, jamais vu durant l'entraînement. Ces deux mesures ne sont **pas comparables** directement.

6.1. Métriques Globales

Modèle	Accuracy	Précision (macro)	Rappel (macro)	F1 (macro)	F1 (pond.)
Baseline CNN	56,09 %	53,8 %	57,1 %	51,9 %	56,8 %
Deep CNN	65,19 %	61,2 %	64,6 %	62,4 %	65,1 %
EfficientNet-B0	61,67 %	61,2 %	60,1 %	60,4 %	61,5 %

6.2. Matrices de Confusion




FIGURE 11 – Matrices de confusion normalisées par ligne pour les 3 modèles. La diagonale = rappel par classe. Chaque cellule hors-diagonale = taux de confusion.

6.3. Métriques par Classe (Deep CNN)




FIGURE 12 – Précision, Rappel et F1 par classe pour les 3 modèles.

Émotion	Précision	Rappel	F1	Observation
Happy	0,85	0,86	0,86	Très bien reconnue (sourire distinctif)
Surprise	0,79	0,78	0,79	Bien reconnue (bouche ouverte)
Neutral	0,61	0,59	0,60	Confusion avec Sad et Fear
Angry	0,57	0,58	0,58	Confusion avec Disgust
Disgust	0,44	0,72	0,54	Rappel élevé, précision faible (faux positifs)
Sad	0,52	0,56	0,54	Confondu avec Neutral et Fear
Fear	0,51	0,43	0,47	Classe la plus difficile

6.4. Analyse des Erreurs




FIGURE 13 – Top 10 des confusions du Deep CNN. Fear→Sad est la plus fréquente (21 %).



FIGURE 14 – Exemples d'images mal classées pour les 4 paires de confusion principales.

Les principales confusions ont une explication **physiologique** :

- **Fear → Sad (21 %)** : sourcils levés + bouche ouverte (Fear) ressemblent à sourcils baissés

+ bouche tombante (Sad) sur 48×48 .

- **Sad** → **Neutral** (17,2 %) : tristesse légère quasi-indéfectable à cette résolution.
- **Angry** → **Sad** (14,6 %) et **Sad** → **Angry** (11,0 %) : expressions de tension faciale communes.
- **Disgust** : rappel fort (72 %) mais précision faible (44 %), le sampler sur-prédit Disgust, générant de nombreux faux positifs depuis la classe Angry.

6.5. Sur le Modèle d'Ensemble

Résultat de l'ensemble (moyenne softmax)

Accuracy : 66,41 % F1 macro : 63,98 % F1 pondéré : 66,33 %

Gain vs Deep CNN seul : +1,23 %

Pourquoi nous n'utilisons pas l'ensemble en production : Ce résultat est correct sur le test set, mais il n'est pas **fiable** en généralisation. EfficientNet-B0, l'un des trois membres, est massivement surajusté (écart train/test : +30,6 %). Ses sorties softmax sont **surconfiantes et mal calibrées** sur des données nouvelles. Le gain de +1,23 % observé sur ce test set spécifique peut s'expliquer par des compensations accidentelles entre les erreurs d'EfficientNet et celles des deux autres modèles : cela ne se généralisera pas nécessairement sur des images réelles.

Décision : le Deep CNN seul est le choix de déploiement le plus honnête et le plus robuste.

7 Application Interactive Streamlit

7.1. Présentation

Une application web a été développée avec **Streamlit** pour permettre de tester le modèle interactivement. Elle est accessible en ligne :

<https://fer2013-emotion-recognition.streamlit.app/>

7.2. Fonctionnalités

Fonctionnalité	Description
Upload d'image	Formats JPG, PNG, BMP, WEBP
Capture webcam	Snapshot depuis le navigateur
Détection de visage	Haar cascade OpenCV (région la plus grande)
Graphique soft-max	Barres horizontales pour les 7 émotions
Top-3	Les 3 émotions les plus probables avec scores
Avertissement	Banner si confiance < 45 % (incertitude détectée)
Pipeline visuel	Vue optionnelle brut → débruisé → CLAHE → normalisé

7.3. Observation Critique : Comportement en Conditions Réelles

Observation importante confirmée par les tests webcam :

Le modèle a été entraîné sur des images **48×48 niveaux de gris**, issues de FER2013 (visages centrés, souvent exagérés). Lors des tests depuis une webcam en conditions réelles, les émotions **subtiles disparaissent** après le redimensionnement à 48×48. Pour obtenir une prédiction fiable depuis une webcam, l'expression doit être **légèrement exagérée**.

Ce phénomène illustre le **domain shift** : l'écart entre la distribution d'entraînement (FER2013 : scènes Internet, expressions forcées) et la distribution réelle (webcam : éclairage naturel, expressions spontanées).

7.4. Résultats des Tests Externes

7 photos testées (1 par émotion), inconnues du modèle :

Émotion	Prédiction	Confiance	Correct ?	Note
Angry	Angry	78,4 %		
Disgust	Disgust	97,9 %		Très confiant
Fear	Fear	26,5 %		Faible confiance
Happy	Happy	73,8 %		Test webcam
Neutral	Neutral	39,9 %		Faible confiance
Sad	Sad	52,4 %		
Surprise	Surprise	84,6 %		
Résultat : 7/7 correct (100 %)				

Les faibles confiances sur Fear (26,5 %) et Neutral (39,9 %) sont **cohérentes** avec les F1-scores les plus bas du test set (0,47 et 0,60). Le modèle est incertain là où il devrait l'être, signe d'une bonne calibration relative.

8 Comparaison avec l'État de l'Art

Méthode	Accuracy (test)	Params	Référence
Accord inter-humains (plafond)	~65–70 %	N/A	FER2013 paper
CNN [26]	62,44 %	N/A	Littérature
Deep CNN (ours)	65,19 %	1,33 M	Ce travail
GoogleNet [30]	65,20 %	6,8 M	Littérature
VGG+SVM [29]	66,31 %	138 M	Littérature
Attentional ConvNet [27]	70,02 %	N/A	Littérature
ResNet [34]	72,40 %	25 M	Littérature
VGG [34]	73,28 %	138 M	Littérature
ViT-B/16	75,6 %	86 M	Littérature

Analyse du positionnement

Notre **Deep CNN** atteint **65,19 %** avec seulement **1,33 M** de paramètres.

- **Vs GoogleNet (65,20 % / 6,8 M)** : performance quasi-identique avec **5× moins de paramètres**. Le rapport performance/complexité est excellent.
- **Vs VGG (73,28 % / 138 M)** : écart de 8 points. Cet écart s'explique par la différence de capacité (138 M vs 1,33 M) et par des données d'entraînement supplémentaires utilisées dans ces travaux.
- **Vs plafond humain (~65–70 %)** : notre modèle se situe **exactement au seuil de l'accord inter-annotateurs**. Les marges de progression sur FER2013 sont limitées sans changement de dataset.

9 Analyse Critique Globale

9.1. Ce qui Fonctionne

Points forts du système

- Pipeline de prétraitement rigoureux.** Le débruitage gaussien léger (adapté aux artefacts JPEG de FER2013), la CLAHE (homogénéisation du contraste local) et la normalisation post-CLAHE (sans data leakage) forment un pipeline cohérent et justifié.
- Gestion du déséquilibre de classes.** Le WeightedRandomSampler assure que Disgust (547 images) est vu aussi fréquemment que Happy (8 989 images) pendant l'entraînement.
- Architecture efficiente.** Le Deep CNN atteint le niveau GoogleNet avec $5\times$ moins de paramètres grâce aux blocs d'attention SE qui recalibrent les canaux pertinents.
- Choix du modèle de production justifié.** Le Deep CNN est privilégié à l'ensemble malgré ses $-1,23\%$ d'accuracy, en raison de la fiabilité de sa généralisation (écart train/val : $+4,8\%$).
- Calibration de l'incertitude cohérente.** Les classes difficiles (Fear, Neutral) déclenchent correctement des avertissements de faible confiance dans l'application.

9.2. Limitations Identifiées

- Plafond intrinsèque de FER2013.** L'accord inter-humains est de $\sim 65\%$. Notre modèle ($65,19\%$) est déjà à cette limite. Progresser significativement nécessiterait un dataset moins bruité (RAF-DB, AffectNet) ou une annotation plus fine.
- Domain shift webcam / FER2013.** FER2013 contient des expressions internet souvent exagérées. En conditions réelles (webcam, expressions spontanées), les émotions subtiles disparaissent après redimensionnement à 48×48 . Le modèle est moins robuste hors de la distribution d'entraînement.
- EfficientNet : domain shift extrême.** ImageNet (RGB, 224×224) et FER2013 (niveaux de gris, 48×48) sont trop éloignés. Le backbone mémorise au lieu de généraliser.
- Disgust : compromis rappel/précision.** Le sampler élève le rappel (72%) mais crée de nombreux faux positifs (précision 44%). Une régularisation plus fine du sampler améliorerait cela.
- Ambiguïté irréductible.** Fear, Sad et Neutral sont intrinsèquement ambigus à 48×48 pixels. Cette ambiguïté est confirmée par les confusions physiologiquement cohérentes observées.

9.3. Pistes d'Amélioration

- Changer de dataset :** AffectNet (450 K images, conditions réelles) ou RAF-DB (30 K, expressions spontanées) réduiraient le domain shift.
- Augmentations avancées :** Mixup, CutMix ou RandAugment pour améliorer la régu-

larisation du Deep CNN.

3. **Architecture moderne** : ConvNeXt-Tiny ou ViT léger entraîné from scratch sur 48×48 grayscale pourrait franchir 70 %.
4. **Détection de visage moderne** : remplacer le Haar cascade (2001) par MediaPipe pour améliorer la robustesse du recadrage en conditions réelles.

10 Conclusion

Bilan du Projet : 5 Semaines

Ce projet a couvert l'intégralité d'un pipeline de deep learning appliqué à un problème réel de vision par ordinateur.

Réalisations techniques :

- Pipeline de prétraitement justifié étape par étape, corrigé en S3 pour éliminer un data leakage sur les statistiques de normalisation.
- Trois architectures implémentées, entraînées et comparées rigoureusement.
- Évaluation objective sur test set indépendant (7 178 images).
- Application web déployée et testée en conditions réelles.

Résultat principal : Le **Deep CNN** ($\sim 1,33$ M paramètres) atteint **65,19 % d'accuracy** sur le test set, au niveau de GoogleNet avec $5\times$ moins de paramètres, et au seuil du plafond humain de FER2013.

Leçons scientifiques :

- La capacité d'un modèle (nombre de paramètres) ne garantit pas la performance si le domaine d'entraînement est trop éloigné (EfficientNet).
- Un ensemble de modèles n'améliore pas nécessairement la fiabilité si ses membres sont mal calibrés.
- Le plafond d'un dataset est une limite réelle ; atteindre 65 % sur FER2013 n'est pas un échec, c'est la limite de l'accord humain.
- Les erreurs du modèle (Fear $\rightarrow$ Sad, Sad $\rightarrow$ Neutral) ont des explications physiologiques, signe que le modèle capture des patterns réels.